

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
Instituto de Ciências Exatas e Informática
Curso de Ciência de Dados e Inteligência Artificial

ANÁLISE DE PADRÕES DE MOBILIDADE URBANA UTILIZANDO A BASE NYC YELLOW TAXI TRIP DATA

Trabalho Final da Disciplina de Processamento de Dados Massivos

André Luiz Santos Moreira da Silva
Bruno Petrocchi de Sena Azevedo
Sara Alves Martins

Trabalho apresentado à disciplina de Processamento de Dados Massivos, do curso de Ciência de Dados e Inteligência Artificial da Pontifícia Universidade Católica de Minas Gerais, como requisito parcial para avaliação da disciplina.

Professor: Lucas Miguel Simões Ponce

Belo Horizonte – MG
2026

1. Introdução	4
2. Objetivos	5
2.1 Objetivo Geral	5
2.2 Objetivos Específicos	5
3. Descrição da Base	6
3.1 Origem dos Dados	6
3.2 Estrutura dos Dados	6
Tabela 1 – Principais atributos da base NYC Yellow Taxi Trip Data	6
3.3 Qualidade dos Dados	7
4. Arquitetura	8
4.1 Visão Geral da Arquitetura	8
4.2 Camada Raw	9
4.3 Camada Silver	9
4.4 Camada Gold	9
4.5 Orquestração da Solução	10
5. Pipeline	10
5.1 Visão Geral	10
5.2 Ingestão dos Dados	10
5.3 Limpeza e Validação dos Dados	11
5.4 Enriquecimento dos Dados	11
5.5 Geração das Tabelas Analíticas	11
Tabela 2 – Conjuntos de dados analíticos da camada Gold	12
5.6 Exportação dos Resultados	12
5.7 Orquestração do Fluxo	13
6. Tecnologias	13
6.1 Apache Spark	13
6.2 Apache Airflow	13
6.3 Python	14
6.4 Apache Parquet	14
6.5 GitHub	14
6.6 Ferramentas de Visualização	14
6.7 Integração das Tecnologias	14
7. Métricas e Indicadores	15
7.1 Visão Geral	15
7.2 Indicadores de Demanda	15
7.3 Indicadores Operacionais	16
7.4 Indicadores Financeiros	16
7.5 Indicadores Geográficos	16
7.6 Indicadores de Pagamento	17
7.7 Importância dos Indicadores	17

Tabela 3 – Resumo das tabelas analíticas geradas	17
8. Resultados e Análises	18
8.1 Visão Geral dos Resultados	18
Tabela 4 – Resultados produzidos pela camada Gold	18
8.2 Análise Temporal da Demanda	19
8.3 Operacional das Viagens	19
8.4 Análise Financeira	19
8.5 Distribuição da Demanda por Região	20
8.6 Formas de Pagamento	20
8.7 Considerações sobre os Resultados	20
9. Conclusão	20
10. Fundamentação Teórica	21
10.1 Big Data	21
10.2 Processamento Distribuído	21
10.3 Apache Spark	22
10.4 Apache Airflow	22
10.5 Arquitetura Medallion	22
11. Referências Bibliográficas	23

Repositório do Projeto

Todo o código-fonte desenvolvido para este trabalho foi disponibilizado em um repositório GitHub, contendo os scripts de ingestão, processamento e geração das tabelas analíticas, bem como a configuração da DAG utilizada para orquestração do pipeline.

O repositório reúne a implementação completa das camadas Raw, Silver e Gold, os artefatos necessários para execução do Apache Spark e Apache Airflow, além da documentação técnica relacionada ao projeto.

Repositório GitHub:

<https://github.com/lismid/Analise-de-padrees-de-mobilidade-urbana-NYC.git>

A disponibilização do código-fonte contribui para a reprodutibilidade dos resultados apresentados neste trabalho e facilita futuras evoluções da solução desenvolvida.

Resumo

Este trabalho apresenta o desenvolvimento de um pipeline de processamento de dados massivos utilizando a base pública NYC Yellow Taxi Trip Data, composta por milhões de registros de corridas de táxi realizadas na cidade de Nova York. Foram analisados dados referentes aos meses de janeiro de 2015, janeiro de 2016, fevereiro de 2016 e março de 2016, totalizando aproximadamente 2 GB de informações.

A solução foi implementada utilizando Apache Spark para processamento distribuído e Apache Airflow para orquestração das etapas do pipeline. A arquitetura adotada seguiu o modelo Medallion, estruturando os dados em camadas Raw, Silver e Gold. Durante o processamento foram realizadas etapas de ingestão, validação, limpeza, transformação e agregação dos dados, incluindo tratamento de valores nulos, remoção de registros inconsistentes e criação de atributos derivados para análise.

A partir dos dados processados foram gerados indicadores relacionados à mobilidade urbana, incluindo volume de viagens por período, distribuição das formas de pagamento, receita das corridas, horários de pico e padrões de demanda. Os resultados foram consolidados em conjuntos analíticos destinados à construção de dashboards e relatórios.

O projeto demonstra a aplicação prática de técnicas de Big Data e processamento distribuído em um cenário real de grande volume de dados, evidenciando a importância de arquiteturas escaláveis para armazenamento, transformação e análise de informações.

Palavras-chave: Big Data; Apache Spark; Apache Airflow; Processamento Distribuído; Mobilidade Urbana.

1. Introdução

O crescimento da digitalização dos serviços e das atividades humanas tem resultado na geração contínua de grandes volumes de dados. Nesse cenário, organizações públicas e privadas utilizam tecnologias de Big Data para armazenar, processar e analisar informações em escala, transformando dados brutos em conhecimento útil para apoio à tomada de decisões. Entre os diversos setores que produzem grandes quantidades de dados, destaca-se a mobilidade urbana. Serviços de transporte geram diariamente milhões de registros contendo informações sobre deslocamentos, horários, localização geográfica, tarifas e comportamento dos usuários. A análise desses dados permite compreender padrões de movimentação da população, identificar períodos de maior demanda e apoiar iniciativas relacionadas ao planejamento urbano e à otimização de serviços de transporte.

A cidade de Nova York disponibiliza publicamente, por meio da Taxi and Limousine Commission (TLC), registros detalhados das corridas realizadas por sua frota de táxis. A base NYC Yellow Taxi Trip Data é amplamente utilizada em pesquisas acadêmicas e projetos de análise de dados devido ao seu elevado volume de registros e à diversidade de informações disponíveis, incluindo horários de embarque e desembarque, distância

percorrida, quantidade de passageiros, coordenadas geográficas e valores financeiros associados às viagens.

Neste contexto, o presente trabalho propõe a construção de um pipeline de processamento de dados massivos utilizando registros de corridas de táxi da cidade de Nova York. A solução foi desenvolvida utilizando Apache Spark para processamento distribuído e Apache Airflow para orquestração das etapas do fluxo de dados, adotando uma arquitetura baseada no modelo Medallion, composta pelas camadas Raw, Silver e Gold.

O projeto contempla desde a ingestão e tratamento dos dados até a geração de indicadores analíticos relacionados à mobilidade urbana, incluindo volume de viagens, padrões temporais de demanda, distribuição dos meios de pagamento e métricas operacionais das corridas. Dessa forma, busca-se demonstrar a aplicação prática de conceitos de Engenharia de Dados e Big Data em um cenário real de grande volume de informações.

Além de atender aos requisitos propostos pela disciplina, o trabalho permite consolidar conhecimentos relacionados ao processamento distribuído, qualidade de dados, construção de pipelines e análise de dados em larga escala, evidenciando a importância dessas tecnologias para o tratamento de problemas contemporâneos baseados em dados.

2. Objetivos

2.1 Objetivo Geral

Desenvolver um pipeline de processamento de dados massivos utilizando a base NYC Yellow Taxi Trip Data, aplicando técnicas de armazenamento, processamento distribuído e orquestração de workflows para analisar padrões de mobilidade urbana na cidade de Nova York.

2.2 Objetivos Específicos

1. Realizar a ingestão e o armazenamento dos dados da base NYC Yellow Taxi Trip Data em uma arquitetura adequada para processamento em larga escala.
2. Implementar um pipeline de processamento distribuído utilizando Apache Spark para executar operações de limpeza, transformação e enriquecimento dos dados.
3. Identificar e tratar inconsistências presentes na base, garantindo maior qualidade e confiabilidade das informações analisadas.
4. Estruturar os dados em camadas Raw, Silver e Gold, promovendo organização, rastreabilidade e reprodutibilidade do processamento.
5. Utilizar o Apache Airflow para automatizar e orquestrar as etapas do pipeline de dados.
6. Gerar indicadores analíticos relacionados à mobilidade urbana, incluindo métricas temporais, operacionais, financeiras e geográficas.
7. Aplicar os conceitos de Big Data e Engenharia de Dados estudados na disciplina em um cenário real de processamento de grandes volumes de dados.

3. Descrição da Base

3.1 Origem dos Dados

A base de dados utilizada neste trabalho é a NYC Yellow Taxi Trip Data, disponibilizada publicamente pela Taxi and Limousine Commission (TLC) da cidade de Nova York. Essa base reúne registros detalhados das corridas realizadas pelos táxis amarelos da cidade, sendo amplamente utilizada em pesquisas acadêmicas e projetos de análise de dados devido ao seu elevado volume de informações e diversidade de atributos.

Para o desenvolvimento do projeto foram utilizados os seguintes conjuntos de dados:

- yellow_tripdata_2015-01
- yellow_tripdata_2016-01
- yellow_tripdata_2016-02
- yellow_tripdata_2016-03

Em conjunto, os arquivos totalizam aproximadamente 2 GB de dados e contêm milhões de registros de corridas realizadas em diferentes períodos.

3.2 Estrutura dos Dados

Cada registro da base representa uma corrida individual de táxi e contém informações operacionais, temporais, geográficas e financeiras.

Os principais atributos utilizados durante o projeto são apresentados na Tabela 1.

Tabela 1 – Principais atributos da base NYC Yellow Taxi Trip Data

Atributo	Descrição
VendorID	Identificador da empresa responsável pelo registro da corrida
tpep_pickup_datetime	Data e horário de início da corrida
tpep_dropoff_datetime	Data e horário de término da corrida
passenger_count	Quantidade de passageiros transportados
trip_distance	Distância percorrida durante a viagem
pickup_longitude	Longitude do ponto de embarque

pickup_latitude	Latitude do ponto de embarque
dropoff_longitude	Longitude do ponto de desembarque
dropoff_latitude	Latitude do ponto de desembarque
RateCodeID	Código tarifário aplicado à corrida
payment_type	Forma de pagamento utilizada
fare_amount	Valor base da corrida
tip_amount	Valor da gorjeta
tolls_amount	Valor gasto com pedágios
total_amount	Valor total pago pelo passageiro

Esses atributos permitem a construção de indicadores relacionados ao comportamento da demanda, padrões de deslocamento, características operacionais das viagens e aspectos financeiros do serviço.

3.3 Qualidade dos Dados

Durante a análise inicial da base foram identificadas inconsistências que exigiram tratamento antes da realização das análises. Entre os principais problemas observados destacam-se:

- Registros com coordenadas geográficas inválidas;
- Corridas com distância igual ou inferior a zero;
- Valores nulos em campos críticos;
- Registros duplicados;
- Durações inconsistentes entre embarque e desembarque;
- Valores financeiros negativos ou inválidos.

Essas inconsistências foram tratadas durante a etapa de processamento da camada Silver, garantindo maior qualidade e confiabilidade aos dados utilizados nas análises posteriores.

A existência dessas situações reforça a importância dos processos de validação e limpeza em projetos de Engenharia de Dados, especialmente quando se trabalha com grandes volumes de informação provenientes de sistemas operacionais reais.


4. Arquitetura

4.1 Visão Geral da Arquitetura

A arquitetura desenvolvida para este projeto foi concebida com o objetivo de garantir organização, escalabilidade e rastreabilidade durante todo o ciclo de processamento dos dados. Para isso, foi adotado o modelo Medallion, amplamente utilizado em projetos modernos de Engenharia de Dados, estruturando as informações em três camadas distintas: Raw, Silver e Gold.

O processamento dos dados foi realizado por meio do Apache Spark, enquanto a orquestração das etapas do pipeline ficou sob responsabilidade do Apache Airflow. Essa combinação permitiu automatizar o fluxo de transformação dos dados e garantir a execução ordenada das atividades.

De forma simplificada, o fluxo do sistema pode ser representado conforme o diagrama a seguir.



4.2 Camada Raw

A camada Raw representa o primeiro nível de armazenamento dos dados. Nessa etapa são mantidos os registros provenientes da fonte original, preservando suas características e garantindo rastreabilidade para futuras reexecuções do pipeline.

Durante a ingestão, os arquivos originais foram convertidos para o formato Parquet e enriquecidos com metadados relacionados à origem e ao período de referência dos dados.

4.3 Camada Silver

A camada Silver é responsável pela preparação dos dados para análise. Nessa etapa são executadas rotinas de limpeza, validação e enriquecimento dos registros.

Entre as principais operações realizadas destacam-se:

- Remoção de registros inválidos;
- Tratamento de valores nulos;
- Eliminação de coordenadas geográficas inconsistentes;
- Remoção de duplicidades;
- Validação das distâncias percorridas;
- Validação da duração das viagens;
- Criação de atributos derivados para análise temporal e operacional.

O resultado dessa etapa é um conjunto de dados consistente e adequado para geração de indicadores analíticos.

4.4 Camada Gold

A camada Gold concentra os dados refinados produzidos pelo pipeline. Nessa etapa são geradas tabelas analíticas destinadas ao consumo por dashboards e relatórios.

Os principais conjuntos produzidos são:

- Viagens por hora;
- Viagens por dia da semana;
- Receita por período;
- Estatísticas de distância e duração;
- Demanda por região;
- Distribuição das formas de pagamento;
- Horários de pico.

Essas tabelas representam o produto final do processamento e servem como base para as análises apresentadas neste trabalho.

4.5 Orquestração da Solução

A execução das etapas do pipeline foi automatizada por meio do Apache Airflow. O fluxo foi modelado como uma DAG (Directed Acyclic Graph), garantindo que cada etapa seja executada somente após a conclusão bem-sucedida da etapa anterior.

O processo é composto pelas seguintes fases:

1. Ingestão dos dados na camada Raw;
2. Limpeza e transformação para geração da camada Silver;
3. Construção das tabelas analíticas da camada Gold;
4. Exportação dos resultados para consumo analítico.

Essa abordagem garante maior controle operacional, facilidade de monitoramento e reprodutibilidade do processamento.

5. Pipeline

5.1 Visão Geral

O pipeline desenvolvido neste projeto foi implementado utilizando Apache Spark para processamento distribuído dos dados e Apache Airflow para automação das etapas de execução. O fluxo foi estruturado de forma sequencial, iniciando pela ingestão dos arquivos de origem e finalizando na geração de conjuntos analíticos destinados a dashboards e relatórios.

A execução do pipeline foi dividida em quatro etapas principais: ingestão dos dados, tratamento e enriquecimento das informações, geração das tabelas analíticas e exportação dos resultados.

5.2 Ingestão dos Dados

A primeira etapa do processo consistiu na leitura dos arquivos da base NYC Yellow Taxi Trip Data referentes aos períodos selecionados para análise.

Durante a ingestão, os dados foram convertidos para o formato Parquet e armazenados na camada Raw. Além dos atributos originais da base, foram adicionados metadados para rastreabilidade do processamento, incluindo:

- Arquivo de origem (*source_file*);
- Data e horário de ingestão (*ingestion_timestamp*);
- Mês de referência dos dados (*ref_month*).

Essas informações permitem identificar a origem dos registros e facilitam futuras auditorias ou reprocessamentos.

5.3 Limpeza e Validação dos Dados

Após a ingestão, os registros passaram por uma etapa de validação e limpeza para garantir a qualidade das informações utilizadas nas análises.

Foram aplicadas as seguintes regras de tratamento:

- Remoção de registros com valores nulos em campos críticos;
- Remoção de registros duplicados;
- Eliminação de coordenadas geográficas fora dos limites válidos da cidade de Nova York;
- Exclusão de corridas com distância igual ou inferior a zero;
- Remoção de viagens com duração inválida;
- Exclusão de viagens com duração superior a 240 minutos;
- Validação da quantidade de passageiros;
- Remoção de registros com valores financeiros negativos.

Ao final dessa etapa foi gerada a camada Silver, contendo dados consistentes e preparados para processamento analítico.

5.4 Enriquecimento dos Dados

Com os dados já validados, foram criados novos atributos derivados para apoiar as análises posteriores.

As principais colunas geradas foram:

- Duração da viagem em minutos (*trip_duration_min*);
- Hora da corrida (*pickup_hour*);
- Dia da semana (*pickup_dayofweek*);
- Data da corrida (*pickup_date*);
- Mês da corrida (*pickup_month*);
- Velocidade média da viagem (*avg_speed_mph*).

Esses atributos permitiram a construção de indicadores temporais e operacionais sem necessidade de recalcular informações durante as etapas analíticas.

5.5 Geração das Tabelas Analíticas

A partir dos dados armazenados na camada Silver foram produzidas as tabelas analíticas da camada Gold.

Foram gerados os seguintes conjuntos de dados:

Tabela 2 – Conjuntos de dados analíticos da camada Gold

Tabela	Finalidade
trips_by_hour	Quantidade de viagens por hora
trips_by_weekday	Quantidade de viagens por dia da semana
revenue_by_period	Receita agregada por período
distance_duration_stats	Estatísticas de distância e duração
demand_by_region	Demanda por região
payment_type_distribution	Distribuição das formas de pagamento
peak_hours	Identificação dos horários de pico

5.6 Exportação dos Resultados


Na etapa final do processo, as tabelas produzidas na camada Gold foram exportadas em formato CSV para um diretório específico de consumo analítico.

Esse procedimento permite a integração direta dos resultados com ferramentas de visualização, como Power BI e Streamlit, simplificando a construção de dashboards e relatórios.

A exportação automatizada garante que os resultados estejam sempre sincronizados com a versão mais recente dos dados processados.

5.7 Orquestração do Fluxo

A execução do pipeline foi automatizada por meio de uma DAG do Apache Airflow composta pelas seguintes tarefas:



Cada etapa é executada somente após a conclusão bem-sucedida da anterior, garantindo consistência e confiabilidade ao processo de processamento dos dados.

6. Tecnologias

A implementação do projeto envolveu a utilização de ferramentas voltadas para processamento distribuído, orquestração de workflows, armazenamento de dados e visualização analítica. A integração dessas tecnologias permitiu a construção de um pipeline completo para ingestão, transformação e análise dos dados da base NYC Yellow Taxi Trip Data.

6.1 Apache Spark

O Apache Spark foi utilizado como principal ferramenta de processamento distribuído do projeto. Sua função consistiu na leitura dos dados, aplicação das regras de limpeza e validação, criação de atributos derivados e geração das tabelas analíticas da camada Gold.

Além do processamento dos dados, o Spark também foi responsável pela conversão dos arquivos para o formato Parquet e pela exportação dos resultados finais.

6.2 Apache Airflow

O Apache Airflow foi utilizado para automatizar e orquestrar a execução das etapas do pipeline. Por meio de uma DAG (Directed Acyclic Graph), a ferramenta controlou a sequência de execução das tarefas de ingestão, tratamento, geração das tabelas analíticas e exportação dos resultados.

Sua utilização garantiu maior controle operacional e reprodutibilidade do fluxo de processamento.

6.3 Python

A linguagem Python foi utilizada no desenvolvimento dos scripts responsáveis pela implementação do pipeline. Sua integração com o ecossistema Spark, por meio do PySpark, permitiu a construção das rotinas de transformação e processamento dos dados.

Além disso, o Python foi utilizado na definição das tarefas executadas pelo Apache Airflow.

6.4 Apache Parquet

O formato Parquet foi adotado para armazenamento das camadas Raw, Silver e Gold devido às suas características de compressão e eficiência em consultas analíticas.

A utilização desse formato contribuiu para otimizar o armazenamento dos dados e melhorar o desempenho das operações realizadas pelo Spark.

6.5 GitHub

O GitHub foi utilizado para armazenamento e versionamento do código-fonte do projeto. A plataforma permitiu o gerenciamento das alterações realizadas ao longo do desenvolvimento e facilitou a organização dos scripts implementados.


6.6 Ferramentas de Visualização

Os resultados produzidos pelo pipeline foram exportados em formato CSV para consumo por ferramentas de visualização e Business Intelligence. Essa etapa permite a construção de dashboards e relatórios destinados à análise dos indicadores gerados pelo processamento dos dados.

6.7 Integração das Tecnologias

A arquitetura desenvolvida baseou-se na integração entre todas as tecnologias descritas anteriormente. Cada ferramenta desempenhou uma função específica dentro do pipeline, contribuindo para a construção de uma solução completa e escalável.

O fluxo tecnológico do projeto pode ser resumido da seguinte forma:



A combinação dessas ferramentas permitiu atender aos requisitos do projeto, fornecendo uma solução capaz de realizar ingestão, processamento distribuído, armazenamento estruturado, automação e disponibilização dos resultados para análise.

7. Métricas e Indicadores

7.1 Visão Geral

Após a execução das etapas de ingestão, tratamento e transformação dos dados, foram definidos indicadores capazes de representar diferentes aspectos da mobilidade urbana observada na cidade de Nova York. Esses indicadores foram gerados a partir dos dados consolidados na camada Gold e utilizados como base para as análises apresentadas neste trabalho.

Os indicadores produzidos foram agrupados em quatro categorias principais: demanda, operação, finanças e comportamento de pagamento.

7.2 Indicadores de Demanda

Os indicadores de demanda foram utilizados para medir o volume de utilização do serviço de táxi ao longo do tempo.

As métricas geradas incluem:

- Quantidade de viagens por hora do dia;
- Quantidade de viagens por dia da semana;
- Identificação dos horários de pico de utilização.

Esses indicadores permitem compreender a distribuição temporal das corridas e identificar períodos de maior demanda.

7.3 Indicadores Operacionais

Os indicadores operacionais foram utilizados para caracterizar o comportamento das viagens realizadas.

As métricas produzidas incluem:

- Distância média percorrida;
- Duração média das viagens;
- Estatísticas agregadas de deslocamento.

Esses dados permitem avaliar o perfil dos deslocamentos observados na base analisada.

7.4 Indicadores Financeiros

Os indicadores financeiros foram utilizados para analisar os valores gerados pelas corridas registradas.

As métricas produzidas incluem:

- Receita agregada por período;
- Valores financeiros associados às viagens processadas.

Esses indicadores permitem avaliar a dimensão econômica do serviço de transporte analisado.

7.5 Indicadores Geográficos

Os indicadores geográficos foram construídos a partir das informações de localização presentes na base de dados.

As métricas geradas incluem:

- Distribuição da demanda por região;
- Áreas com maior concentração de viagens.

Esses indicadores auxiliam na compreensão dos padrões espaciais de mobilidade urbana.

7.6 Indicadores de Pagamento

A base analisada também permitiu avaliar o comportamento dos passageiros em relação aos meios de pagamento utilizados.

Para isso foi gerado um indicador de distribuição das formas de pagamento, possibilitando identificar os métodos mais utilizados ao longo do período analisado.

7.7 Importância dos Indicadores

A Tabela 3 apresenta os conjuntos analíticos gerados na camada Gold e utilizados nas análises deste trabalho.

Tabela 3 – Resumo das tabelas analíticas geradas

Tabela Analítica	Descrição
trips_by_hour	Quantidade de viagens por hora
trips_by_weekday	Quantidade de viagens por dia da semana
revenue_by_period	Receita agregada por período
distance_duration_stats	Estatísticas de distância e duração
demand_by_region	Demanda agregada por região
payment_type_distribution	Distribuição dos meios de pagamento
peak_hours	Identificação dos horários de pico

Esses conjuntos de dados constituem o produto final do pipeline analítico e servem como base para os resultados apresentados na próxima seção.

8. Resultados e Análises

8.1 Visão Geral dos Resultados

Após a execução do pipeline de processamento distribuído, os dados foram consolidados na camada Gold e organizados em tabelas analíticas destinadas à exploração e visualização dos resultados.

Foram produzidos sete conjuntos de dados analíticos, cada um responsável por representar um aspecto específico da mobilidade urbana observada na base NYC Yellow Taxi Trip Data.

A Tabela 4 apresenta os artefatos gerados pelo pipeline.

Tabela 4 – Resultados produzidos pela camada Gold

Tabela	Finalidade
trips_by_hour	Quantidade de viagens por hora
trips_by_weekday	Quantidade de viagens por dia da semana
revenue_by_period	Receita agregada por período
distance_duration_stats	Estatísticas de distância e duração
demand_by_region	Demanda agregada por região
payment_type_distribution	Distribuição dos meios de pagamento
peak_hours	Horários de pico

Esses conjuntos foram posteriormente exportados para arquivos CSV, permitindo sua utilização em ferramentas de visualização e análise.

8.2 Análise Temporal da Demanda

Para análise temporal foram geradas as tabelas *trips_by_hour*, *trips_by_weekday* e *peak_hours*. Esses conjuntos permitem avaliar a distribuição das corridas ao longo das horas do dia e dos diferentes dias da semana.

A tabela *trips_by_hour* registra o volume de viagens para cada hora do dia, juntamente com o valor médio arrecadado por corrida naquele período. Já a tabela *trips_by_weekday* permite comparar o comportamento da demanda entre os diferentes dias da semana.

Complementando essas análises, a tabela *peak_hours* identifica os cinco horários de maior movimentação para cada mês analisado, possibilitando identificar períodos de pico na utilização do serviço.

8.3 Operacional das Viagens

Os indicadores operacionais foram consolidados na tabela *distance_duration_stats*.

Essa tabela reúne métricas relacionadas à distância média percorrida, duração média das viagens e velocidade média observada nas corridas processadas. Essas informações permitem caracterizar o perfil dos deslocamentos realizados pelos passageiros e avaliar aspectos relacionados à eficiência operacional do serviço.

A utilização de métricas agregadas reduz a complexidade da análise e facilita a comparação entre diferentes períodos da base.

8.4 Análise Financeira

Os indicadores financeiros foram produzidos por meio da tabela *revenue_by_period*.

Essa agregação consolida informações como:

- Quantidade total de corridas;
- Receita total gerada;
- Soma das tarifas;
- Soma das gorjetas;
- Soma dos pedágios;
- Valor médio das gorjetas.

Essas métricas permitem avaliar a dimensão econômica do serviço e compreender a composição da arrecadação gerada pelas corridas registradas na base.

8.5 Distribuição da Demanda por Região

A tabela *demand_by_region* foi utilizada para analisar a distribuição espacial das viagens.

Como a base utilizada não possui identificadores oficiais de zonas geográficas, a regionalização foi realizada por meio do agrupamento das coordenadas de embarque em grades geográficas aproximadas, construídas a partir do arredondamento das latitudes e longitudes registradas nos dados.

Essa abordagem possibilitou identificar áreas com maior concentração de corridas e estimar padrões geográficos de demanda sem a necessidade de bases cartográficas complementares.

8.6 Formas de Pagamento

A análise dos meios de pagamento foi realizada por meio da tabela *payment_type_distribution*.

Além do volume de corridas por modalidade de pagamento, essa tabela também apresenta indicadores financeiros associados a cada método utilizado, incluindo receita total e valor médio das gorjetas.

A categorização dos pagamentos foi realizada a partir dos códigos presentes na base original, permitindo distinguir transações realizadas por cartão de crédito, dinheiro e outras modalidades registradas pelo sistema.

8.7 Considerações sobre os Resultados

Os resultados produzidos demonstram a capacidade do pipeline em transformar dados operacionais brutos em conjuntos analíticos estruturados e prontos para consumo por ferramentas de visualização e análise.

A utilização do Apache Spark permitiu processar grandes volumes de registros de forma distribuída, enquanto a arquitetura adotada garantiu organização, rastreabilidade e reutilização dos dados gerados. Os conjuntos produzidos constituem uma base adequada para construção de dashboards, análises exploratórias e estudos relacionados à mobilidade urbana.

9. Conclusão

O presente trabalho teve como objetivo desenvolver um pipeline de processamento de dados massivos utilizando a base NYC Yellow Taxi Trip Data, aplicando técnicas de armazenamento, processamento distribuído e orquestração de workflows. A solução implementada permitiu realizar a ingestão, tratamento, transformação e análise de milhões de registros de corridas de táxi da cidade de Nova York.

Por meio da utilização do Apache Spark e do Apache Airflow, foi possível construir um fluxo automatizado capaz de processar os dados de forma organizada e reproduzível. A estruturação em camadas permitiu separar os dados brutos, os dados tratados e os conjuntos analíticos gerados ao final do processamento.

Como resultado, foram produzidas tabelas analíticas contendo indicadores relacionados à demanda por viagens, comportamento temporal das corridas, distribuição geográfica da demanda, características operacionais das viagens, indicadores financeiros e formas de pagamento utilizadas pelos passageiros. Esses conjuntos foram disponibilizados para consumo por ferramentas de visualização e análise de dados.

Durante o desenvolvimento do projeto também foram identificados desafios relacionados à qualidade dos dados, incluindo registros inconsistentes, coordenadas inválidas, valores ausentes e duplicidades. A implementação de regras de validação e limpeza contribuiu para aumentar a confiabilidade dos resultados produzidos.

Dessa forma, conclui-se que os objetivos propostos foram alcançados, demonstrando a aplicação prática dos conceitos estudados na disciplina em um cenário real de processamento de dados em larga escala. Como trabalhos futuros, sugere-se a ampliação da análise para períodos adicionais da base de dados, a integração com fontes externas de informação e a aplicação de técnicas de aprendizado de máquina para previsão de demanda e identificação de padrões mais complexos de mobilidade urbana.

10. Fundamentação Teórica

10.1 Big Data

O termo Big Data é utilizado para descrever conjuntos de dados cujo volume, complexidade ou velocidade de geração dificultam seu processamento por ferramentas tradicionais. Em projetos dessa natureza, torna-se necessário utilizar tecnologias capazes de armazenar, processar e analisar grandes quantidades de informação de forma eficiente.

A base NYC Yellow Taxi Trip Data apresenta características compatíveis com esse contexto, reunindo milhões de registros de corridas de táxi distribuídos ao longo do tempo. Embora o volume utilizado neste trabalho seja relativamente moderado para padrões industriais, ele é suficiente para demonstrar os desafios relacionados ao processamento de dados em larga escala e justificar o uso de ferramentas especializadas.

10.2 Processamento Distribuído

O processamento distribuído consiste na divisão de tarefas computacionais entre múltiplos recursos de processamento, permitindo que grandes volumes de dados sejam manipulados de forma paralela. Essa abordagem oferece vantagens importantes em relação ao processamento tradicional, incluindo redução do tempo de execução, melhor utilização dos recursos computacionais e maior capacidade de escalabilidade.

No contexto deste trabalho, o processamento distribuído foi utilizado para executar operações de leitura, limpeza, transformação e agregação sobre milhões de registros da base de dados analisada.

10.3 Apache Spark

O Apache Spark é um framework open source voltado para processamento distribuído de dados. Sua arquitetura permite a execução paralela de operações analíticas, tornando-o uma das ferramentas mais utilizadas em projetos de Engenharia de Dados e Big Data.

Neste projeto, o Spark foi empregado em todas as etapas de processamento da informação, incluindo ingestão dos arquivos de origem, validação dos registros, transformação dos dados e geração das tabelas analíticas utilizadas nas análises finais.

Sua utilização permitiu implementar um pipeline capaz de processar grandes quantidades de dados de forma eficiente e organizada.

10.4 Apache Airflow

O Apache Airflow é uma plataforma utilizada para automação e orquestração de workflows. Sua principal função é controlar a execução de processos compostos por múltiplas etapas interdependentes.

Os fluxos são organizados por meio de DAGs (Directed Acyclic Graphs), que definem a sequência de execução das tarefas e suas dependências.

Neste trabalho, o Airflow foi utilizado para automatizar o pipeline de processamento, coordenando as etapas de ingestão dos dados, geração da camada Silver, criação das agregações da camada Gold e exportação dos resultados finais.

10.5 Arquitetura Medallion

A arquitetura Medallion é uma abordagem utilizada para organizar pipelines de dados em diferentes níveis de refinamento. Seu objetivo é separar claramente os dados brutos, os dados tratados e os dados prontos para consumo analítico.

A estrutura é normalmente dividida em três camadas:

- **Raw (Bronze):** armazenamento dos dados originais;
- **Silver (Prata):** dados tratados, validados e enriquecidos;
- **Gold (Ouro):** dados agregados e preparados para análise.

Essa arquitetura foi adotada no projeto por facilitar a rastreabilidade do processamento, melhorar a qualidade dos dados e simplificar a geração dos indicadores analíticos utilizados nas etapas finais do trabalho.

11. Referências Bibliográficas

APACHE AIRFLOW. *Apache Airflow Documentation*. Disponível em: <https://airflow.apache.org/docs/>. Acesso em: 21 jun. 2026.

APACHE SPARK. *Apache Spark Documentation*. Disponível em: <https://spark.apache.org/docs/latest/>. Acesso em: 21 jun. 2026.

CHAMBERS, Bill; ZAHARIA, Matei. *Spark: The Definitive Guide: Big Data Processing Made Simple*. Sebastopol: O'Reilly Media, 2018.

DATARICKS. *What is Medallion Architecture?* Disponível em: <https://www.databricks.com/glossary/medallion-architecture>. Acesso em: 21 jun. 2026.

KLEPPMANN, Martin. *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. Sebastopol: O'Reilly Media, 2017.

NEW YORK CITY TAXI AND LIMOUSINE COMMISSION (TLC). *TLC Trip Record Data*. Disponível em: <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>. Acesso em: 21 jun. 2026.

ZAHARIA, Matei et al. Apache Spark: A Unified Engine for Big Data Processing. *Communications of the ACM*, v. 59, n. 11, p. 56–65, 2016.